Inteligência Artificial

Redes Neurais Artificiais

Universidade Estadual do Paraná - Unespar

27 de Junho de 2024

Conceitos

- Computador:
  - Melhor em cálculo e lógica;
  - Multi-tarefas;
  - Base elétrica.
- Humano:
  - Melhor em raciocínio e criação;
  - Aprendizagem;
  - Base elétrica (Reação química).

Conceitos

- Redes neurais artificiais (RNA);
- Surgimento na década de 50;
- Popular tema de pesquisa científica;
- A partir 1990.

Aplicações

- Avaliação de imagens ruidosas;
- Controle automatizado de equipamentos;
- Sistema de controle e previsão financeira;
- Identificação de anomalias e patologias em bases de sinais digitais;
- Reconhecimento facial;
- Classificação de padrões de escrita e fala.

Conceitos

- RNAs são modelos computacionais inspirados no sistema nervoso;
- Possuem a capacidade de:
  - Aquisição;
  - Manutenção;
  - Conhecimento.
- Caracterizada pela unidade de processamento:
  - Neurônio;
  - Como é representado computacionalmente?

Conceitos

- Principais características:
    - Adaptação por experiência;
    - Capacidade de aprendizado;
    - Habilidade de generalização;
    - Organização de dados;
    - Tolerância a falhas;
    - Facilidade de prototipagem.

Neurônios

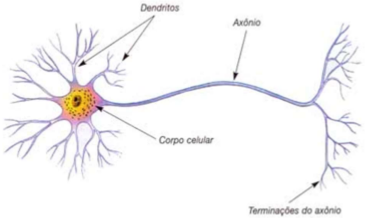
Dendritos
Axônio
Corpo celular
Terminações do axônio

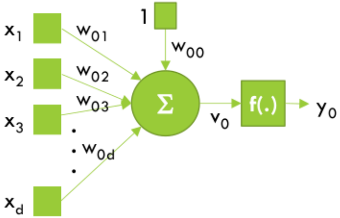
1
x_1
x_2
x_3
x_d
w_{00}
w_{01}
w_{02}
w_{03}
w_{0d}
Σ
v_0
f(.)
y_0

Conceitos

- Entradas:
  - Sinais ou medidas que representam as variações aceitas.
- Pesos sinápticos:
  - Valores de ponderação da relevância das entradas.
- Combinador linear:
  - Agregador de valores de entradas, produzindo um potencial de ativação.
- Limiar de ativação:
  - Identificador de variação apropriada para o resultado.

Neurônios Artificiais

- Potencial de ativação:
  - Resultado produzido com a função soma e o limiar de ativação.
- Função de ativação:
  - Limitador da saída em um intervalo assumido pela arquitetura da RNA.
- Bias (viés):
  - Valor adicional somado ao potencial de ativação, permitindo o ajuste da função de ativação.
- Saída:
  - Valor final produzido pelo neurônio em relação ao conjunto de entrada.

Função de ativação

- Degrau (Hard Limiter);
- Degrau Bipolar (Symmetric Hard Limiter);
- Rampa simétrica;
- Relu.

Perceptron

- Frank Rosenblatt em 1957;
- Aprendizagem Supervisionada;
- Base para o desenvolvimento de modelos mais avançados;
- Incapacidade de lidar com problemas não linearmente separáveis.

Perceptron

- Um perceptron é um modelo linear;
  - Resolve problemas linearmente separáveis;
- Classes que podem ser separadas por um hiperplano são ditas linearmente separáveis;
- Perceptron encontrará um hiperplano separador;
- Não necessariamente o melhor hiperplano.

Perceptron

- O treinamento de um perceptron corresponde ao processos de encontrar valores dos pesos;
- Diminuir o erro produzido pelos neurônios;
- Aprendizado por correção de erro;
- Processo iterativo;
- Muitas épocas;
- Erro seja suficientemente pequeno.

Perceptron

- Inicializar todos os pesos com zero;
- **Até** que todos os exemplos de treino sejam corretamente classificados **faça**:
  - **Para** cada dado D do conjunto de treino **faça**:
    - **Se** D for incorretamente classificado **faça**:
    - Calcule o erro e atualize os pesos.

Perceptron

- Aprendizagem por correção de erro:
  - Se o resultado não é o desejado é necessário ajustar o peso dos neurônios para um valor proporcional ao sinal de entrada;
  - Atualização dos pesos:
    - $W_{novo} = W_{atual} + TaxaAprendizagem * Erro * SinalDeEntrada$
    - $Erro(\Delta) = saidaDesejada - saidaObtida$
    - $TaxaAprendizagem(n) = [0, 1]$
    - $SinalEntrada = valorEntrada_j$

Exemplo: Função AND

- Taxa de aprendizagem $= 1$;
- Função de ativação:
  - 1 se > 0;
  - 0 se $<= 0$;

Table: Porta lógica AND

AND	bias	a1	a2	y
E_1	1	0	0	0
E_2	1	0	1	0
E_3	1	1	0	0
E_4	1	1	1	1

- $w_0 = 0, w_1 = 0, w_2 = 0$

$$E1: y = f(w_0a_0 + w_1a_1 + w_2a_2)$$
$$= f(0\times1+0\times0+0\times0) = f(0) = 0 \rightarrow y = d$$
$$w_0 = 0 \qquad w_1 = 0 \qquad w_2 = 0$$

$$E2: y = f(0\times1+0\times0+0\times1) = f(0) = 0 \rightarrow y = d$$
$$w_0 = 0 \qquad w_1 = 0 \qquad w_2 = 0$$

$$E3: y = f(0\times1+0\times1+0\times0) = f(0) = 0 \rightarrow y = d$$
$$w_0 = 0 \qquad w_1 = 0 \qquad w_2 = 0$$

$$E4: y = f(0\times1+0\times1+0\times1) = f(0) = 0 \rightarrow y \neq d$$
$$w0 = 0+1*(1-0)*1=1 \qquad w1 = 0+1*(1-0)*1=1 \qquad w2 = 0+1*(1-0)*1=1$$

Exemplo: Função AND (2º Epoca)

- $w_0 = 1, w_1 = 1, w_2 = 1$

E1: $y = f(w_0 a_0 + w_1 a_1 + w_2 a_2)$
$= f(1\times1+1\times0+1\times0) = f(1) = 1 \rightarrow y \neq d$
$w_0=1+1*(0-1)*1=0$ $w_1=1+1*(0-1)*0=1$ $w_2=1+1*(0-1)*0=1$

E2: $y = f(0\times1+1\times0+1\times1) = f(1) = 1 \rightarrow y \neq d$
$w_0= 0-1= -1$ $w_1=1-0=1$ $w_2=1-1=0$

E3: $y = f(-1\times1+1\times1+0\times0) = f(0) = 0 \rightarrow y = d$
$w_0= -1$ $w_1=1$ $w_2=0$

E4: $y = f(-1\times1+1\times1+0\times1) = f(0) = 0 \rightarrow y \neq d$
$w_0= -1+1=0$ $w_1=1+1=2$ $w_2=0+1=1$

Exemplo: Função AND (3º Epoca)

- $w_0 = 0, w_1 = 2, w_2 = 1$

E1: $y = f(w_0 a_0 + w_1 a_1 + w_2 a_2)$
$= f(0\times1+2\times0+1\times0) = f(0) = 0 \rightarrow y = d$
$w_0=0 \quad w_1=2 \quad w_2=1$

E2: $y = f(0\times1+2\times0+1\times1) = f(1) = 1 \rightarrow y \neq d$
$w_0=0-1=-1 \quad w_1=2-0=2 \quad w_2=1-1=0$

E3: $y = f(-1\times1+2\times1+0\times0) = f(1) = 1 \rightarrow y \neq d$
$w_0= -1-1=-2 \quad w_1=2-1=1 \quad w_2=0$

E4: $y = f(-2\times1+1\times1+0\times1) = f(-1) = 0 \rightarrow y \neq d$
$w_0= -2+1=-1 \quad w_1=1+1=2 \quad w_2=0+1=1$

Exemplo: Função AND (4º Epoca)

- $w_0 = -1, w_1 = 2, w_2 = 1$

E1: $y = f(w_0a_0 + w_1a_1 + w_2a_2)$
$= f(-1\times1+2\times0+1\times0) = f(-1) = 0 \rightarrow y = d$
w_0=-1 w_1=2 w_2=1

E2: $y = f(-1\times1+2\times0+1\times1) = f(0) = 0 \rightarrow y = d$
w_0=-1 w_1=2 w_2=1

E3: $y = f(-1\times1+2\times1+1\times0) = f(1) = 1 \rightarrow y \neq d$
w_0= -1-1=-2 w_1=2-1=1 w_2=1-0=1

E4: $y = f(-2\times1+1\times1+1\times1) = f(0) = 0 \rightarrow y \neq d$
w_0= -2+1=-1 w_1=1+1=2 w_2=1+1=2

Exemplo: Função AND (5º Epoca)

- $w_0 = -1, w_1 = 2, w_2 = 2$

E1: $y = f(w_0 a_0 + w_1 a_1 + w_2 a_2)$
$= f(-1\times1+2\times0+2\times0) = f(-1) = 0 \rightarrow y = d$
$w_0=-1 \quad w_1=2 \quad w_2=2$

E2: $y = f(-1\times1+2\times0+2\times1) = f(1) = 1 \rightarrow y \neq d$
$w_0=-1-1=-2 \quad w_1=2-0=2 \quad w_2=2-1=1$

E3: $y = f(-2\times1+2\times1+1\times0) = f(0) = 0 \rightarrow y = d$
$w_0= -2 \quad w_1=2 \quad w_2=1$

E4: $y = f(-2\times1+2\times1+1\times1) = f(1) = 1 \rightarrow y = d$
$w_0= -2 \quad w_1=2 \quad w_2=1$

Exemplo: Função AND (6º Epoca)

- $w_0 = -2, w_1 = 2, w_2 = 1$

E1: $y = f(w_0a_0 + w_1a_1 + w_2a_2)$
$= f(-2\times1+2\times0+1\times0) = f(-2) = 0 \rightarrow y = d$

E2: $y = f(-2\times1+2\times0+1\times1) = f(-1) = 0 \rightarrow y = d$

E3: $y = f(-2\times1+2\times1+1\times0) = f(0) = 0 \rightarrow y = d$

E4: $y = f(-2\times1+2\times1+1\times1) = f(1) = 1 \rightarrow y = d$

$\boxed{w_0 = -2 \quad w_1 = 2 \quad w_2 = 1}$

Limitação Perceptron

- Se os dados forem linearmente separáveis:
  - Algoritmo termina em número finito de iterações;
- Caso contrário o algoritmo não terminará:
  - Número máximo de épocas;
  - Não tem garantia sobre a qualidade do modelo de saída;
- Redes de uma única camadas resolvem apenas problemas linearmente separáveis;
- Porta lógica XOR.

Função XOR

	a_1	a_2	y
E_1	0	0	0
E_2	0	1	1
E_3	1	0	1
E_4	1	1	0

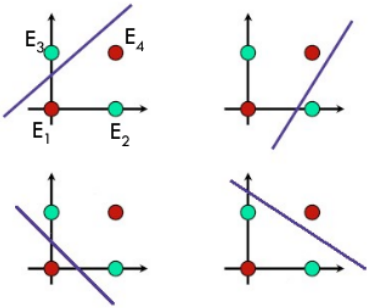

Solução?

- Utilizar mais de uma camada!
    - Multi-Layer Perceptron (MLP);
    - Redes Neurais Convolucionais (CNNs);
    - Redes Neurais Recorrentes (RNNs);
    - Redes Neurais Generativas Adversariais (GANs);

Obrigado!
Dúvidas?

Guilherme Henrique de Souza Nakahata

guilhermenakahata@gmail.com

https://github.com/GuilhermeNakahata/UNESPAR-2024